Documento de soporte – Proyecto Olist

ANÁLISIS DE LOS FACTORES QUE DETERMINAN LA SATISFACCIÓN DEL CLIENTE EN OLIST

Valentina Ramírez

0000330524

Aprendizaje de máquina No Supervisado

Universidad de La Sabana

2026-I

1. ENLACE AL DATASET

Dataset en Kaggle: Brazilian E-Commerce Public Dataset by Olist
https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce

2. JUSTIFICACIÓN DE LA SELECCIÓN DE ARCHIVOS Y DE LA PREGUNTA DE NEGOCIO

Se seleccionaron los archivos Orders, order_items, reviews, Products, Customers, sellers y geolocation para responder la pregunta: ¿qué factores determinan la satisfacción del cliente en Olist? ¿El tiempo de entrega, la distancia o el tipo de producto explican mejor la calificación recibida? Esta combinación permite construir una base final donde cada fila representa una orden entregada con reseña, un solo vendedor y una sola categoría de producto, lo que hace posible interpretar correctamente los resultados. orders aporta las fechas para calcular tiempos de entrega y tardanza; reviews permite medir satisfacción; order_items y products incorporan el tipo de producto y sus características; Customers, sellers y geolocation permite calcular la distancia real entre vendedor y cliente, la selección es adecuada porque conecta directamente la pregunta de negocio con variables logísticas, geográficas y comerciales, y además permite aplicar de forma coherente las técnicas exigidas en el curso: Máxima verosimilitud, inferencia bayesiana, simulación Monte Carlo y Clustering.

3. TABLA DE RESULTADOS

3.1 Resultados de máxima verosimilitud (MLE)

Distribución	LogLik	Parámetros libres (k)	AIC	BIC
Log-Normal	**-310182.2073**	**2**	**620368.4146**	**620387.2863**
Gamma	**-310438.4607**	**2**	**620880.9214**	**620899.7931**
Exponencial	**-323327.9069**	**1**	**646657.8138**	**646667.2496**
Normal	**-339737.3979**	**2**	**679478.7958**	**679497.6675**

Modelo ganador: Log-Normal.
Diferencia frente al segundo mejor modelo: 512.5068 puntos en AIC y BIC.

Interpretación breve: la distribución Log-Normal fue la que mejor representó el comportamiento del tiempo de entrega. Esto indica que la mayoría de las órdenes se entregan en pocos días, pero existe una cola de pedidos mucho más lentos que afecta de forma importante la experiencia del cliente.

3.2 Parámetros del posterior

Parámetro	Valor
alpha_posterior	6479.6864
beta_posterior	44400.3136
media_posterior	0.1274
n_actual	50778
k_negativas	6467

Interpretación: en 2018, la probabilidad posterior global de reseña negativa fue de 12.74%. Esto significa que, con base en la evidencia disponible, aproximadamente 1 de cada 8 órdenes terminó en una experiencia claramente insatisfactoria.

3.3 Métricas de clustering

K	Inercia	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	530371.4807	0.2742	1.9330	17745.8026
3	448122.6414	0.2805	1.6414	18998.5502
4	392975.0310	0.2561	1.5187	18774.1472

5	356902.2905	0.2575	1.3196	17843.1593
6	324987.7286	0.2664	1.2743	17494.6367

K seleccionado: 3.

Justificación: fue el valor con mejor equilibrio entre separación e interpretabilidad, al presentar el mayor índice de Silhouette y el mayor valor de Calinski-Harabasz. La guía pide precisamente reportar Silhouette, Davies-Bouldin y Calinski-Harabasz como parte de las métricas de validación.

Interpretación breve: el clustering permitió identificar tres perfiles de experiencia de compra con diferencias claras en tiempo de entrega, distancia, tipo de producto y satisfacción.

4. REPOSITORIO GITHUB

Enlace al repositorio personal con los notebooks comentados y ejecutados:
https://github.com/valentina-00Ramirez/proyecto-olist-ml-no-supervisado/tree/main

5. Nota final

Este documento resume los principales resultados cuantitativos del análisis realizado sobre el dataset de Olist y acompaña el video de presentación y el repositorio con los notebooks ejecutados.